Reporte Metodológico

Predicción de Rendimiento de Cebada

mediante Modelado Espacial e Integración Fenológica

Convocatoria

Reto AgroCebada FIRA 2026

Fideicomisos Instituidos en Relación con la Agricultura

Equipo

Fruty Loops

Ángel Gabriel Munguía Velázquez • Física
Saul Tellez Mastranzo • Ing. en Sistemas Computacionales
Marcela Abril Sánchez Orea • Ciencias de Datos
Rosh Guadiana Paez • Ing. Biomédica

Ciclo Primavera-Verano 2025 • Altiplano Central de México

Puebla • Hidalgo • Tlaxcala

Índice

1. Introducción **2**

2. Justificación **3**

3. Objetivos **3**

4. Metodología **4**

4.1. Datos, Extracción Espacial y Preprocesamiento 4

4.2. Ingeniería de Variables Fenológicas y Bloques Temáticos 4

4.3. Arquitectura del Pipeline, Modelos y Esquemas de Validación 4

5. Resultados y Discusión **5**

5.1. Geoestadística: Estructura Espacial a Múltiples Escalas 5

5.2. Comparativa de Modelos, Degradación Espacial y Prueba de Residuos 6

5.3. Respuestas a las Preguntas Guía (Interpretabilidad SHAP y Ablación) 6

6. Uso de la Ciencia de Datos en la Inclusión Financiera del Sector Agro **7**

7. Conclusiones **8**

8. Bibliografía **8**

9. Anexos **10**

1 Introducción

La predicción precisa del rendimiento agrícola constituye un pilar estratégico para la seguridad alimentaria, la planeación agroindustrial y la mitigación de riesgos climáticos y financieros. En la región del Altiplano Central de México, el cultivo de cebada representa una actividad económica de alta relevancia productiva, sujeta a una marcada variabilidad climática interanual, heterogeneidad topográfica y prácticas de manejo diferenciadas entre productores. El **Reto AgroCebada FIRA 2026** plantea el desafío científico y operativo de desarrollar modelos predictivos robustos utilizando registros climáticos, modelos digitales de elevación e información de percepción remota (índices espectrales de vegetación, agua y suelo), prescindiendo inherentemente de variables agronómicas de manejo a nivel de predio, tales como la variedad específica de semilla, la densidad y fecha exacta de siembra, el esquema de fertilización o el historial de rotación del suelo.

El presente trabajo documenta la metodología implementada para modelar el rendimiento en grano (toneladas por hectárea, t/ha) sobre un universo de **197 polígonos agrícolas** monitoreados durante la ventana del ciclo primavera-verano, comprendida entre el 1 de abril y el 31 de octubre de 2025. El conjunto de datos se divide oficialmente en una cohorte de desarrollo de **138 parcelas** con rendimiento observado (media de 3.96 t/ha, mediana de 4.34 t/ha y desviación estándar de 0.85 t/ha, en un rango de 2.00 a 5.59 t/ha) y una cohorte de validación ciega de **59 parcelas** destinadas a la predicción final. Espacialmente, los predios abarcan superficies desde 0.35 hasta 64.30 hectáreas (media de 6.60 ha) y se distribuyen en tres entidades federativas y nueve municipios:

- **Puebla**: 100 parcelas concentradas en Chignahuapan.
- **Hidalgo**: 51 parcelas en Singuilucan, Almoloya, Cuautepec de Hinojosa, Emiliano Zapata, Apan y Tepeapulco.
- **Tlaxcala**: 46 parcelas en Calpulalpan y Nanacamilpa de Mariano Arista.

Inicialmente, el problema se abordó desde una perspectiva estrictamente biofísica, postulando que las series temporales de índices satelitales (como NDVI, EVI, LAI o FAPAR) y la acumulación termo-pluviométrica explicarían directamente la varianza productiva. Sin embargo, la auditoría exploratoria de los sensores satelitales evidenció retos importantes de cobertura debido a la nubosidad estacional (promedios de **32.5 %** en Sentinel-2, **38.7 %** en Landsat y **36.6 %** en Planet dentro del ciclo), lo que obligó a trabajar mediante agregaciones mensuales robustas. Al analizar la distribución territorial, observamos que el rendimiento exhibe una fuerte autocorrelación espacial estructurada en múltiples escalas. Conforme a la *Primera Ley de la Geografía de Tobler*, las parcelas cercanas presentan rendimientos altamente similares, un fenómeno que los algoritmos flexibles de aprendizaje automático suelen explotar como atajos matemáticos. Por ello, este reporte detalla una arquitectura diseñada para auditar las fugas de información espacial, separar rigurosamente la interpolación geográfica del aporte satelital real y entregar un ensamble cuyas métricas e intervalos de incertidumbre operan bajo total transparencia analítica.

2 Justificación

En el aprendizaje automático aplicado a la agricultura de precisión, es frecuente que algoritmos altamente parametrizados confundan la autocorrelación espacial con relaciones causales biológicas. Cuando parcelas vecinas comparten microclima, pendiente y prácticas culturales regionales, e ingresan simultáneamente en entrenamiento y prueba mediante validaciones cruzadas aleatorias, los modelos tienden a memorizar la ubicación geográfica a través de covariables ambientales de baja resolución.

Además, el diagnóstico satelital del reto demostró que ningún sensor garantiza cobertura continua sin nubes durante los meses críticos de espigamiento y llenado de grano (julio a septiembre), con valores faltantes de hasta 54.9 % en índices ópticos del conjunto Básico y 30.5 % en Planet. La justificación central de nuestra metodología radica en fusionar ambas colecciones satelitales con datos climáticos e indicadores fenológicos, y en separar estadísticamente la interpolación espacial del aporte neto de la percepción remota. Adoptar este estándar previene el sobreajuste geográfico y permite proporcionar a FIRA estimaciones de error realistas, diferenciando entre zonas con referencias cercanas y territorios nuevos sin calibración local.

3 Objetivos

Objetivo General

Objetivo General

Desarrollar, validar e interpretar un modelo predictivo para la estimación del rendimiento de cebada (t/ha) que integre series temporales multisensor (Sentinel-2, Landsat y Planet), variables climáticas (CHIRPS/CHIRTS) y topográficas (INEGI), cuantificando estadísticamente el peso relativo de la ubicación geográfica frente a las variables agronómicas y fenológicas derivadas de percepción remota.

Objetivos Específicos

1. Ejecutar un diagnóstico de cobertura y calidad espectral entre sensores ópticos, construyendo una matriz integrada de **187 características** organizadas en ocho bloques temáticos (suelo/térmico, vegetación, agua, clima, topografía, física, fenología y área).
2. Sintetizar la dinámica temporal del cultivo mediante métricas fenológicas e indicadores físicos interpretables, incluyendo el área bajo la curva (AUC), tasas máximas de cambio mensual (Delta máximo), amplitud intercuartílica (IQR), mes pico de vigor vegetativo y cocientes heurísticos de estrés termo-hídrico.
3. Aplicar validación local (`RepeatedKFold`), agrupación por celdas CHIRPS (`GroupKFold`) y extrapolación municipal (`Leave-One-Group-Out`); además, analizar la semivarianza espacial.
4. Auditar el aporte neto de cada bloque de variables mediante estudios de ablación, regresión sobre residuos espaciales e importancia agrupada (SHAP y permutación), seleccionando el modelo final bajo una regla de decisión fijada de antemano.

4 Metodología

4.1 Datos, Extracción Espacial y Preprocesamiento

El flujo de trabajo se estructuró sobre las 197 parcelas del reto, acotadas a la ventana agrícola de abril a octubre de 2025. A partir del archivo vectorial (`EPSG:4326`), se validó la consistencia geométrica de los polígonos reproyectándolos al sistema métrico `EPSG:6372` (ITRF2008 LCC de México), confirmando una correlación de **1.0000** (diferencia relativa media de 0.68 %) frente a la superficie oficial reportada en hectáreas (`AREA_HA`). Para el análisis geoestadístico de distancias euclidianas en metros, los centroides fueron transformados a la proyección UTM Zona 14N (`EPSG:32614`), mientras que para la búsqueda de vecinos en producción se empleó distancia geodésica de Haversine.

Las variables ambientales se extrajeron de **146 archivos ráster GeoTIFF** mediante estadísticas zonales (`rasterstats` con criterio `all_touched=True`, tras alinear el sistema de referencia de cada capa). Se estandarizaron los valores nulos (`NoData = -9999` o inferiores a `-9000` como `NaN`) y se filtraron exclusivamente los siete meses del ciclo, obteniendo **21 variables climáticas mensuales** a resolución ∼5 km (7 de precipitación CHIRPS en mm, 7 de temperatura máxima CHIRTS y 7 de temperatura mínima CHIRTS en °C) y **2 variables topográficas** del INEGI CEM 4.0 a 120 m (elevación en metros y pendiente en grados).

Para las observaciones satelitales, se procesaron **16,296 capturas** del conjunto Básico (9,986 de Sentinel-2 y 6,310 de Landsat, con 23 índices espectrales) y **26,255 capturas** del conjunto PRO (Planet, con 4 índices: NDVI, EVI, LAI y MSAVI). Se verificó la coherencia interna de los estadísticos por captura (mín $\leq$ promedio $\leq$ máx y std ≥ 0) y se construyeron series mensuales por parcela calculando la mediana mensual del promedio espacial (`*_promedio`), mitigando el sesgo por nubes residuales.

4.2 Ingeniería de Variables Fenológicas y Bloques Temáticos

Se construyeron **187 características** en ocho bloques temáticos: (i) **Fenología** (135 variables): para cada uno de los 23 índices del conjunto Básico y los 4 del PRO (exigiendo al menos 3 meses con dato válido), se extrajeron cinco métricas de la curva temporal: AUC (biomasa acumulada), Delta máximo (tasa de desarrollo o senescencia), P90 (techo de vigor), IQR (amplitud estacional) y Mes del máximo (pico fenológico entre 4 y 10). (ii) **Clima** (21 variables) y **Topografía** (2): series mensuales de precipitación, temperaturas extremas, altitud y pendiente. (iii) **Variables físicas derivadas** (9): integrales estacionales de dosel (FAPAR y NDVI), mes pico de NDVI, precipitación acumulada del ciclo y de llenado de grano, temperaturas medias, amplitud térmica media y un **Cociente Simple de Estrés** (precipitación acumulada / temperatura máxima media durante julio-septiembre). (iv) **Suelo/térmico** (7), **Vegetación** (9), **Agua** (3) y **Área** (1): medianas estacionales de índices específicos (CRC, MCRC, NDSVI, SRNDI, NDTI, STI, MRA, NDVI, EVI, LAI, FAPAR, SAVI, MSAVI, NDWI, DSWI4, DSWI5) y el tamaño del lote (`AREA_HA`).

4.3 Arquitectura del Pipeline, Modelos y Esquemas de Validación

Para impedir cualquier fuga de datos entre particiones, todo el preprocesamiento se encapsuló en objetos `Pipeline` de Scikit-learn. Se evaluaron cinco arquitecturas sobre exactamente las mismas particiones: (1) **Dummy** (`strategy='mean'`) como línea base; (2) **KNN Espacial** (`KNeighborsRegressor`, $k = 5$, pesos inversos a la distancia, entrenado solo con latitud y longitud estandarizadas); (3) **HGB Agronómico** (`HistGradientBoostingRegressor` con

`learning_rate=0.05`, `max_leaf_nodes=7`, `min_samples_leaf=10`, `l2_regularization=10.0`, semilla 999) con las 187 variables, sin coordenadas; (4) **HGB Final** (coordenadas forzadas + 20 mejores variables por `SelectKBest` con información mutua, `learning_rate=0.06`, `max_leaf_nodes=15`, `min_samples_leaf=5`, `l2_regularization=8.0`, semilla 2026); y (5) **Ensamble 50/50** (promedio 0.50 KNN Espacial + 0.50 HGB Final).

Se establecieron tres esquemas de validación: **RepeatedKFold** (5 folds × 3 repeticiones = 15 folds, semilla 999) para medir interpolación en zonas con parcelas intercaladas; **GroupKFold_CHIRPS** (5 folds agrupando las 23 celdas climáticas de 0,05°); y **LOGO_Municipio** (Leave-One-Group-Out sobre los 9 municipios) para evaluar extrapolación. Antes de observar resultados, se fijó la regla de decisión: entregar el Ensamble 50/50 si su MAE medio por fold bajo `RepeatedKFold` no superaba al del KNN Espacial en más de **0.02 t/ha**. La Figura 1 sintetiza el flujo completo.

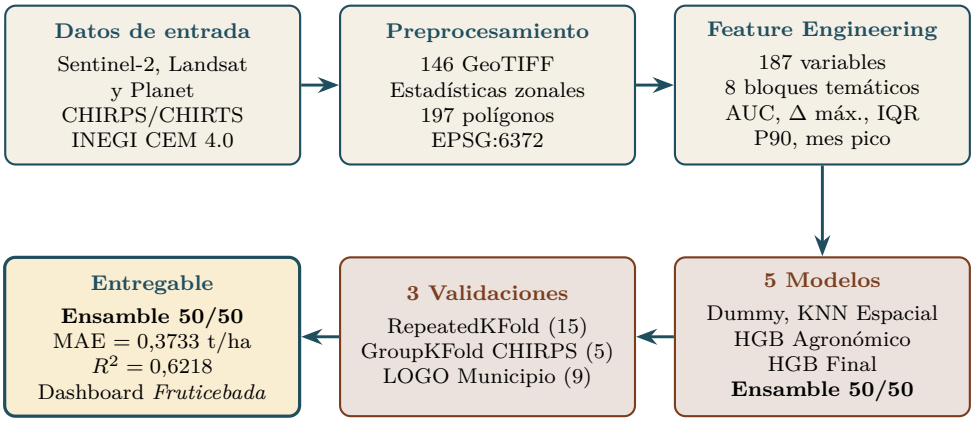


Figura 1. Pipeline metodológico de extremo a extremo del equipo *Fruty Loops*. Los datos de entrada se procesan mediante extracción zonal y feature engineering para construir las 187 variables que alimentan los cinco modelos evaluados bajo tres esquemas de validación, con el Ensamble 50/50 como entregable final.

5 Resultados y Discusión

5.1 Geoestadística: Estructura Espacial a Múltiples Escalas

El rendimiento observado en las 138 parcelas presentó varianza global de **0.7192 (t/ha)²** (sill aproximado) y desviación estándar de 0.85 t/ha. El semivariograma empírico reveló marcada dependencia espacial: $<$ 250 m (0.0897 (t/ha)²), 500 m–1 km (0.3458), 5–10 km (0.2240), 10–25 km (0.8767) y $>$ 25 km (1.0614). La semivarianza a distancias menores a 250 m representa una cota superior del "efecto pepita" equivalente a ∼12.5 % de la varianza total, confirmando elevada homogeneidad productiva entre vecinos inmediatos. Por encima de 25 km, la semivarianza rebasa la varianza global, reflejando gradientes macroclimáticos regionales. Al comparar pares separados entre 2 y 10 km dentro del mismo municipio (n = 4,824, diferencia media 0.5488 t/ha, IC 95 % [0.533, 0.563]) frente a pares en municipios distintos (n = 1,416, diferencia media 0.4248 t/ha, IC 95 % [0.401, 0.448]), se corroboró que la continuidad productiva responde a gradientes geográficos físicos y no a límites administrativos.

5.2 Comparativa de Modelos, Degradación Espacial y Prueba de Residuos

La evaluación sistemática demostró cómo cambia el desempeño al pasar de interpolación local a extrapolación espacial (Tabla 1). Bajo `RepeatedKFold`, el Ensamble 50/50 alcanzó MAE pooled de 0.3733 t/ha y R^2 de 0.6218, mientras que el KNN Espacial obtuvo 0.3706 t/ha y R^2 de 0.6393. La diferencia pareada entre ambos fue de apenas $+\mathbf{0{,}0025 \pm 0{,}0308}$ t/ha (no detectable frente a la desviación entre folds), cumpliendo holgadamente la regla de tolerancia ($\leq 0{,}02$ t/ha) y superando consistentemente al HGB Final individual ($-0{,}0308 \pm 0{,}0273$ t/ha).

Al bloquear celdas climáticas completas (`GroupKFold_CHIRPS`), el HGB Agronómico se degradó de 0.3613 a 0.6111 t/ha ($R^2 = 0{,}0536$), revelando que gran parte de su poder predictivo en validación aleatoria provenía de inferir la ubicación a través de la cuadrícula climática. El Ensamble 50/50 mantuvo MAE pooled de 0.4974 t/ha y R^2 de 0.4433, mostrando mejor robustez. En `LOGO_Municipio`, el error mostró fuerte asimetría regional: Chignahuapan ($n = 71$, MAE 0.371 t/ha), Calpulalpan ($n = 30$, MAE 0.321) y Almoloya ($n = 10$, MAE 0.278) mantuvieron errores bajos, mientras que aislar Singuilucan ($n = 16$) elevó el MAE del Ensamble a 1.461 t/ha. El Ensamble obtuvo MAE pooled de 0.4817 t/ha y R^2 de 0.3045.

La prueba de residuos —predecir los errores fuera de muestra del KNN Espacial con 157 variables satelitales y 186 satelitales más entorno mediante RidgeCV y HGB— arrojó R^2 negativos ($-0{,}0238$ y $-0{,}0164$ con Ridge; $-0{,}1753$ y $-0{,}1656$ con HGB). Esto indica que, al nivel de agregación mensual, la serie satelital no añade varianza ortogonal a la posición geográfica.

Tabla 1. Resultados comparativos por esquema de validación.

Esquema	Modelo	MAE pooled	RMSE pooled	R^2 pooled	MAE fold ± DE
Repeated KFold (15 folds)	Dummy (Media)	0.7521	0.8538	$-0{,}0137$	$0{,}7520 \pm 0{,}0504$
	KNN Espacial	0.3706	0.5092	0.6393	$0{,}3706 \pm 0{,}0661$
	HGB Agronómico	0.3613	0.5206	0.6231	$0{,}3610 \pm 0{,}0734$
	HGB Final	0.4041	0.5685	0.5500	$0{,}4038 \pm 0{,}0780$
	Ensamble 50/50	**0.3733**	**0.5212**	**0.6218**	$\mathbf{0{,}3731 \pm 0{,}0718}$
GroupKFold CHIRPS	KNN Espacial	0.3795	0.5342	0.6033	$0{,}3747 \pm 0{,}0392$
	HGB Agronómico	0.6111	0.8250	0.0536	$0{,}5609 \pm 0{,}4275$
	Ensamble 50/50	**0.4974**	**0.6328**	**0.4433**	$\mathbf{0{,}4804 \pm 0{,}1481}$
LOGO Municipio (9 folds)	Dummy (Media)	1.0674	1.1530	$-0{,}8485$	$0{,}8912 \pm 0{,}3503$
	KNN Espacial	0.4836	0.7192	0.2808	$0{,}4694 \pm 0{,}4344$
	HGB Agronómico	0.3829	0.5453	0.5866	$0{,}2762 \pm 0{,}1729$
	HGB Final	0.4915	0.7064	0.3062	$0{,}5974 \pm 0{,}5036$
	Ensamble 50/50	**0.4817**	**0.7073**	**0.3045**	$\mathbf{0{,}5230 \pm 0{,}4238}$

5.3 Respuestas a las Preguntas Guía (Interpretabilidad SHAP y Ablación)

Las tres preguntas guía —índice más importante, variable climática de mayor peso y combinación óptima— se responden de manera integrada en los tres apartados siguientes, sustentadas en SHAP agrupado a través de 15 folds y en ablación por bloques temáticos. Evaluando el HGB Agronómico (sin coordenadas) para evitar que latitud/longitud eclipsaran la señal biofísica, encontramos:

1. **Índice satelital con mayor peso:** DSWI4 (estrés hídrico del dosel, SHAP $0{,}0546 \pm 0{,}0299$;

ΔMAE por permutación $+0{,}0061 \pm 0{,}0143$), DSWI3 ($0{,}0443 \pm 0{,}0218$; ΔMAE $+0{,}0062 \pm 0{,}0076$), SRNDI ($0{,}0427 \pm 0{,}0185$) y NDTI ($0{,}0382 \pm 0{,}0110$; primero por permutación grupal $+0{,}0066 \pm 0{,}0108$) lideraron la contribución predictiva, seguidos por FAPAR ($0{,}0371 \pm 0{,}0147$) y PRO_NDVI ($0{,}0355 \pm 0{,}0188$). `fenologia__ndti__iqr` apareció en Top 10 en 13/15 folds y `fenologia__srndi__iqr` en 11/15, ambos con baja correlación con ubicación ($|\rho| \leq 0{,}273$); `fenologia__nddi__iqr` mostró correlación moderada con elevación ($\rho = -0{,}507$).

2. **Variable climática más relevante:** Precipitación (PREC) concentró casi toda la importancia del bloque climático (SHAP $0{,}5805 \pm 0{,}0291$; ΔMAE $+0{,}4191 \pm 0{,}0620$), muy por encima de Tmax (0.0068) y Tmin (0.0041). Por ventana temporal, `PREC_2025_05_mean` fue dominante en los 15 folds (SHAP $0{,}5765 \pm 0{,}0295$), capturando la humedad de establecimiento, aunque con fuerte correlación espacial con la longitud ($\rho = -0{,}844$), actuando parcialmente como identificador regional este-oeste.

3. **Mejor combinación (ablación):** ningún bloque aislado compite con el modelo integrado (solo agua $+0{,}3613 \pm 0{,}0904$ t/ha; solo vegetación $+0{,}2753 \pm 0{,}0841$; solo suelo/térmico $+0{,}2731 \pm 0{,}0695$). Eliminar fenología degradó detectablemente el MAE bajo `RepeatedKFold` ($+0{,}0279 \pm 0{,}0255$) y eliminar clima colapsó la generalización inter-municipal bajo LOGO ($+0{,}4058 \pm 0{,}2825$). La combinación óptima integra clima, fenología y anclaje espacial.

6 Uso de la Ciencia de Datos en la Inclusión Financiera del Sector Agro

El modelado predictivo transparente del rendimiento agrícola tiene aplicación directa en el diseño de crédito y aseguramiento paramétrico para pequeños y medianos productores de cebada apoyados por FIRA. Históricamente, la asimetría de información y el alto costo de las inspecciones en campo limitan el acceso a financiamiento formal o encarecen las primas de seguro agropecuario.

Nuestros hallazgos permiten proponer un esquema de evaluación crediticia diferenciada por certidumbre espacial. Dado que el modelo es preciso con parcelas de referencia cercanas (error absoluto medio de 0.37 t/ha bajo interpolación), pero incrementa su incertidumbre en municipios aislados (validación LOGO), sería riesgoso usar predicciones puntuales sin cuantificar su margen de error. Por ello, *Fruticebada* calcula la distancia geodésica desde cada nueva parcela hacia los predios de referencia:

Zonas con referencias cercanas

$\leq 2{,}027$ m (percentil 95): se asigna un intervalo al 80 % de confianza de $\pm 0{,}568$ t/ha. En estas áreas (donde se ubican las 59 parcelas de predicción, con mediana al vecino más cercano de 400 m), FIRA y los intermediarios financieros pueden automatizar la originación de créditos de avío, estimar la capacidad de pago y pre-validar siniestros de forma remota.

Zonas de expansión

$> 2{,}027$ m: el sistema amplía la incertidumbre a $\pm 0{,}760$ t/ha y emite alerta técnica para priorizar muestreo físico o ajustar coberturas, logrando inclusión financiera prudente y escalable. El prototipo funcional, el código fuente y un video demostrativo se adjuntan como entregables tecnológicos.

7 Conclusiones

El desarrollo experimental realizado para el Reto AgroCebada FIRA 2026 permitió establecer un flujo reproducible de extremo a extremo que integra diagnóstico espectral multisensor, ingeniería de variables biofísicas, auditoría geoestadística e interpretabilidad algorítmica. En primer lugar, se concluye que la combinación de observaciones de Sentinel-2, Landsat y Planet resumidas mediante estadísticos robustos (mediana mensual y métricas de curva fenológica como AUC, Delta máximo e IQR) permite subsanar los vacíos de información provocados por la nubosidad estacional durante el ciclo abril-octubre de 2025.

En segundo lugar, la validación rigurosa mediante tres esquemas demostró la importancia crítica de auditar la autocorrelación espacial en modelos agroclimáticos. El análisis geoestadístico confirmó que el rendimiento de cebada en la región obedece a una estructura de doble escala: una alta similitud micro-regional en radios menores a 250 m (asociada a condiciones edáficas y prácticas locales) y una tendencia macro-regional a distancias mayores a 25 km capturada primordialmente por los gradientes de precipitación de mayo (`PREC_2025_05_mean`) y la topografía. Cuando los modelos de árboles potenciados por gradiente se evalúan sin separar grupos espaciales, aprovechan estas variables como coordenadas implícitas; al evaluar bajo extrapolación municipal estricta (`LOGO_Municipio`), el bloque climático resulta indispensable para sostener la generalización regional, evitando una pérdida de +0,406 t/ha en el MAE.

En tercer lugar, dentro de las variables derivadas de percepción remota, los indicadores vinculados al balance hídrico del dosel (**DSWI4**, **DSWI3**) y al manejo de residuos y labranza (**NDTI**, **SRNDI**) aportaron la señal más consistente a través de los 15 folds de validación, superando a los índices tradicionales de verdor simple. Finalmente, el **Ensamble 50/50** (KNN Espacial + HGB Final) seleccionado cumplió el criterio de decisión predefinido (MAE de 0.3733 t/ha y R^2 de 0.6218 en validación cruzada repetida), generando predicciones plausibles y verificadas para las 59 parcelas objetivo (media predicha de 3.962 t/ha frente a 3.955 t/ha del conjunto de entrenamiento) e integrándose directamente en el dashboard interactivo con intervalos de incertidumbre explícitos para respaldar la toma de decisiones financieras en el sector rural mexicano.

8 Bibliografía

[1] Servicio de Información Agroalimentaria y Pesquera (SIAP). (2025). *Anuario Estadístico de la Producción Agrícola en México*. Secretaría de Agricultura y Desarrollo Rural (SADER).

[2] Bivand, R. S., Pebesma, E., & Gómez-Rubio, V. (2013). *Applied Spatial Data Analysis with R* (2nd ed.). Springer.

[3] Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., ... & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes. *Scientific Data*, 2(1), 150066.

[4] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[5] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[6] Fideicomisos Instituidos en Relación con la Agricultura (FIRA). (2026). *Bases de Participación y Lineamientos Técnicos del Reto AgroCebada FIRA 2026*.

9 Anexos

Anexo A. Uso de Inteligencia Artificial (IA)

El desarrollo analítico, la depuración de código y la integración de la plataforma web fueron asistidos por Modelos de Lenguaje Grande (LLMs) —Claude (Anthropic), ChatGPT (OpenAI) y Gemini (Google)— bajo supervisión y validación humana continua. En cumplimiento del apartado de Disposiciones Generales de la convocatoria, a continuación se transcriben **prompts representativos** de cada categoría de uso.

A.1 Ingeniería de datos y pipelines espaciales

> *«Diseña un* `Pipeline` *de* `scikit-learn` *que aplique* `ColumnTransformer` *con imputación por mediana y* `StandardScaler` *a las variables numéricas, seguido de* `SelectKBest` *(*`mutual_info_regression`*,* `k=20`*), garantizando que la selección de variables se ajuste* ***únicamente dentro de cada fold*** *de* `GroupKFold` *para evitar fuga de información entre particiones de validación.»*

A.2 Validación geoestadística e interpretabilidad

> *«Implementa* `LeaveOneGroupOut` *sobre la columna* `municipio` *y calcula el MAE* pooled *como promedio ponderado por fold, además del MAE por fold ± desviación estándar. Adicionalmente, agrupa los valores SHAP por índice espectral (DSWI4, SRNDI, NDTI, etc.) y reporta la media ± DE a través de los 15 folds de* `RepeatedKFold`*.»*

A.3 Documentación y despliegue del dashboard

> *«Revisa la redacción técnica del apartado de Metodología para mantener el conteo de palabras dentro del rango 600–700 exigido por las bases, sin alterar fórmulas, métricas ni la nomenclatura de variables. Verifica la consistencia numérica entre las tablas de resultados y los valores reportados en las libretas reproducibles.»*

Anexo B. Contribuciones del Equipo *Fruty Loops*

Integrante	Licenciatura	Contribución principal
Ángel Gabriel Munguía Velázquez	Física	Preprocesamiento espacial y satelital; ingeniería de características fenológicas (AUC, Delta máximo, IQR, cocientes termo-hídricos); diseño experimental de validación (`RepeatedKFold`, `GroupKFold_CHIRPS`, `LOGO_Municipio`) e interpretabilidad SHAP.
Saul Tellez Mastranzo	Ing. Sistemas Computacionales	Desarrollo del dashboard *Fruticebada*, arquitectura backend, contratos de datos en SQLite y despliegue del prototipo funcional con enlace público.
Marcela Abril Sánchez Orea	Ciencias de Datos	Análisis geoestadístico y cálculo de semivariogramas empíricos; construcción de intervalos empíricos de predicción; prueba de residuos con RidgeCV y HGB.
Rosh Guadiana Paez	Ing. Biomédica	Redacción del informe técnico, revisión metodológica, análisis del esquema de inclusión financiera y edición editorial final.

Fin del Reporte Metodológico

Reto AgroCebada FIRA 2026 • Equipo *Fruty Loops*